1. Билет №9

Файловая система: процесс и файловые структуры связанные с процессом. Файлы и открытые файлы, связь структур, представляющих открытые файлы на разных уровнях. Системный вызов open() и библиотечная функция fopen(): параметры и флаги, определенные на функции open(). Реализация системного вызова open() в ядре Linux. Пример: файл открывается два раза системным вызовом open() для записи и в него последовательно записывается строка
«аааааааааааа» по первому дескриптору и затем строка «вввв» по второму дескриптору, затем файл закрывается два раза. Показать, что будет записано в файл и пояснить результат.

Процесс — это программа в стадии выполнения. Процесс является единицей декомпозицией системы, именно ему выделяются ресурсы системы.

1.1. Файл

Файл — важнейшее понятие в файловой подсистеме. Файл — информация, хранимая во вторичной памяти или во вспомогательном ЗУ с целью ее сохранения после завершения отдельного задания или преодоления ограничений, связанных в объемом основного ЗУ.

Файл — поименованная совокупность данных, хранимая во вторичной памяти (возможно даже целая). Файл — каждая индивидуально идентифицированная единица информации.

Существует 2 ипостаси файла:

1. файл, который лежит на диске;

2. открытый файл (с которым работает процесс).

Открытый файл — файл, который открывает процесс. Для такого файла создается дескриптор файла в таблице открытых файлов процесса (struct files_struct). Но этого мало. Необходимо создать дескриптор открытого файла в системной таблице открытых файлов (struct file).

Файл != место на диске. В мире современной вычислительной техники файлы имеют настолько большие размеры, что не могут храниться в непрерывном физическом адресном пространстве, они хранятся вразброс (несвязанное распределение).

Файл может занимать разные блоки/сектора/дорожки на диске аналогично тому, как память поделена на страницы. В любой фрейм может быть загружена новая страница, как и файл.

Также, важно понимать адресацию.

Соответственно, система должна обеспечить адресацию каждого такого участка.

> ОС является загружаемой программой, её не называют файлом, но когда компьютер включается, ОС находится во вторичной памяти. Затем с помощью нескольких команд, которые находятся в ПЗУ, ОС (программа) загружается в ОЗУ. При этом выполняется огромное количество действий, связанных с управлением памятью, и без ФС это сделать невозможно. Любая ОС без ФС не может быть полноценной.

Задача ФС — обеспечивать сохранение данных и доступ к сохраненным данным (обеспечивать работу с файлами).

Чтобы обеспечить хранение файла и последующий доступ к нему, файл должен быть изолирован, то есть занимать некоторое адресное пространство, и это адресное пространство должно быть защищено. Доступ обеспечивается по тому, как файл идентифицируется в системе (доступ осуществляется по его имени).

ФС — порядок, определяющий способ организации хранения, именования и доступа к данным на вторичных носителях информации.

> File management (управление файлами) — программные процессы, связанные с общим управлением файлами, то есть с размещением во вторичной памяти, контролем доступа к файлам, записью резервных копий, ведением справочников (directory).
>
> Основные функции управления файлами обычно возлагаются на ОС, а дополнительные — на системы управления файлами.

Доступ к файлам: open, read, write, rename, delete, remove.

Разработка UNIX началась с ФС. Без ФС невозможно создание приложений, работающих в режиме пользователя (сложно разделить user mode и kernel mode).

Файловая подсистема взаимодействует практически со всеми модулями ОС, предоставляя пользователю возможность долговременного хранения данных, а также ОС возможность работать с объектами ядра.

1.2. struct file

Существует 2 типа файлов — файл, к-ый лежит на диске и открытый файл. Открытый файл – файл, который открывает процесс

Кратко

struct file описывает открытый файл.

Подробно

Если файл просто лежит на диске, то через дерево каталогов можно увидеть это.

Увидеть можно только подмонтированную ФС.

А есть открытые файлы — файлы, с которыми работают процессы.

Открыть файл может только процесс. Если файл открывается потоком, то он в итоге все равно открывается процессом (как ресурс). Ресурсами владеет процесс.

Таблицы открытых файлов

Помимо таблицы открытых файлов процесса (есть у каждого процесса), в системе есть одна таблица на все открытые файлы (на которую ссылаются таблицы процессов).

Причем в этой таблице на один и тот же файл (с одним и тем же inode) мб создано большое кол-во дескрипторов открытых файлов, т.к. один и тот же файл мб открыт много раз.

Каждое открытие файла с одним и тем же inode приведет к созданию дескриптора открытого файла.

При открытии файла его дескриптор добавляется:

1. в таблицу открытых файлов процесса (struct file_struct)
2. в системную таблицу открытых файлов

Каждый дескриптор struct file имеет поле f_pos. При работе с файлами это надо учитывать.

Один и тот же файл, открытый много раз без соотв. способов взаимоискл. будет атакован, что приведет к потере данных.

~~Гонки при разделении файлов – один и тот же файл мб открыт разными процессами.~~

Определение struct file

```
1    struct file {
2   struct path     f_path;
3   struct inode    *f_inode;   /* cached value */
4   const struct file_operations  *f_op;
5         ...
6   atomic_long_t     f_count;// кол–во жестких ссылок
7   unsigned int      f_flags;
8   fmode_t       f_mode;
9   struct mutex    f_pos_lock;
10  loff_t        f_pos;
11  ...
12  struct address_space  *f_mapping;
13  ...
14 };
```

Как осуществляется отображение файла на физ. страницы? - дескриптор открытого файла имеет указатель на inode (файл на диске).

Связь между struct file и struct file operations

Файл должен быть открыт. Соответственно для открытого файла должен быть создан дескриптор. В этом дескрипторе имеется указатель на struct file_operations. Это либо стандартные (установленные по умолчанию) операции на файлах для конкретной файловой системы, либо зарегистрированные разработчиком (собственные функции работы с файлами собственной файловой системы). В write стоит buf — означает, что write может записать разное количество байт.

```
1   struct file_operations {
2   struct module *owner;
3   loff_t (*llseek) (struct file *, loff_t, int);
4   ssize_t (*read) (struct file *, char __user *, size_t, loff_t *);
5   ssize_t (*write) (struct file *, const char __user *, size_t, loff_t *);
6   ...
7   int (*open) (struct inode *, struct file *);
8   ...
```

```
 9    int (*release) (struct inode *, struct file *);
10    ...
11  } __randomize_layout;
```

1.3. Связи структур

Связи структур при выполнении системных вызовов

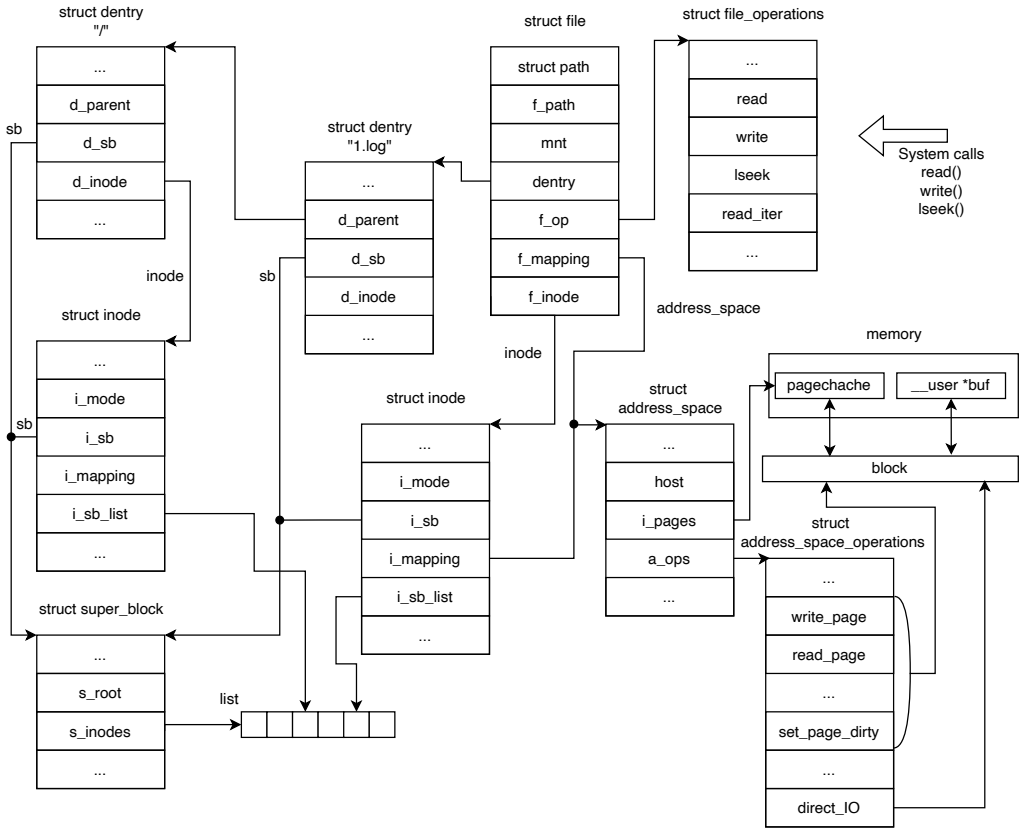

Воспоминания о пояснениях

Указатель f_mapping показывает связь структур, описывающих файлы в системе с памятью. Также в struct inode есть поле i_mapping.

struct super_block содержит список inode (s_inodes). struct inode содержит указатель на соответствующий inode в списке (i_sb_list).

Любая файловая система имеет корневой каталог, а именно от корневого каталога формируется путь к файлу для конкретной файловой системы.

Отправная точка — системные вызовы (read, write, lseek, ...). Здесь нет open(), так как он открывает файл, а использование функций read, write, lseek возможно только при работе с открытым файлом.

Связи структур относительно процесса

Теперь пойдем от процесса: Отправная точка – **struct task_struct**; В **struct task_struct** есть 2 указателя:

- на **struct fs_struct** (*fs); - Любой процесс относится к какой-то файловой системе
- на **struct files_struct** (*files) – дескриптор, описывающий файлы, открытые процессом (Любой процесс имеет собственную таблицу открытых файлов).

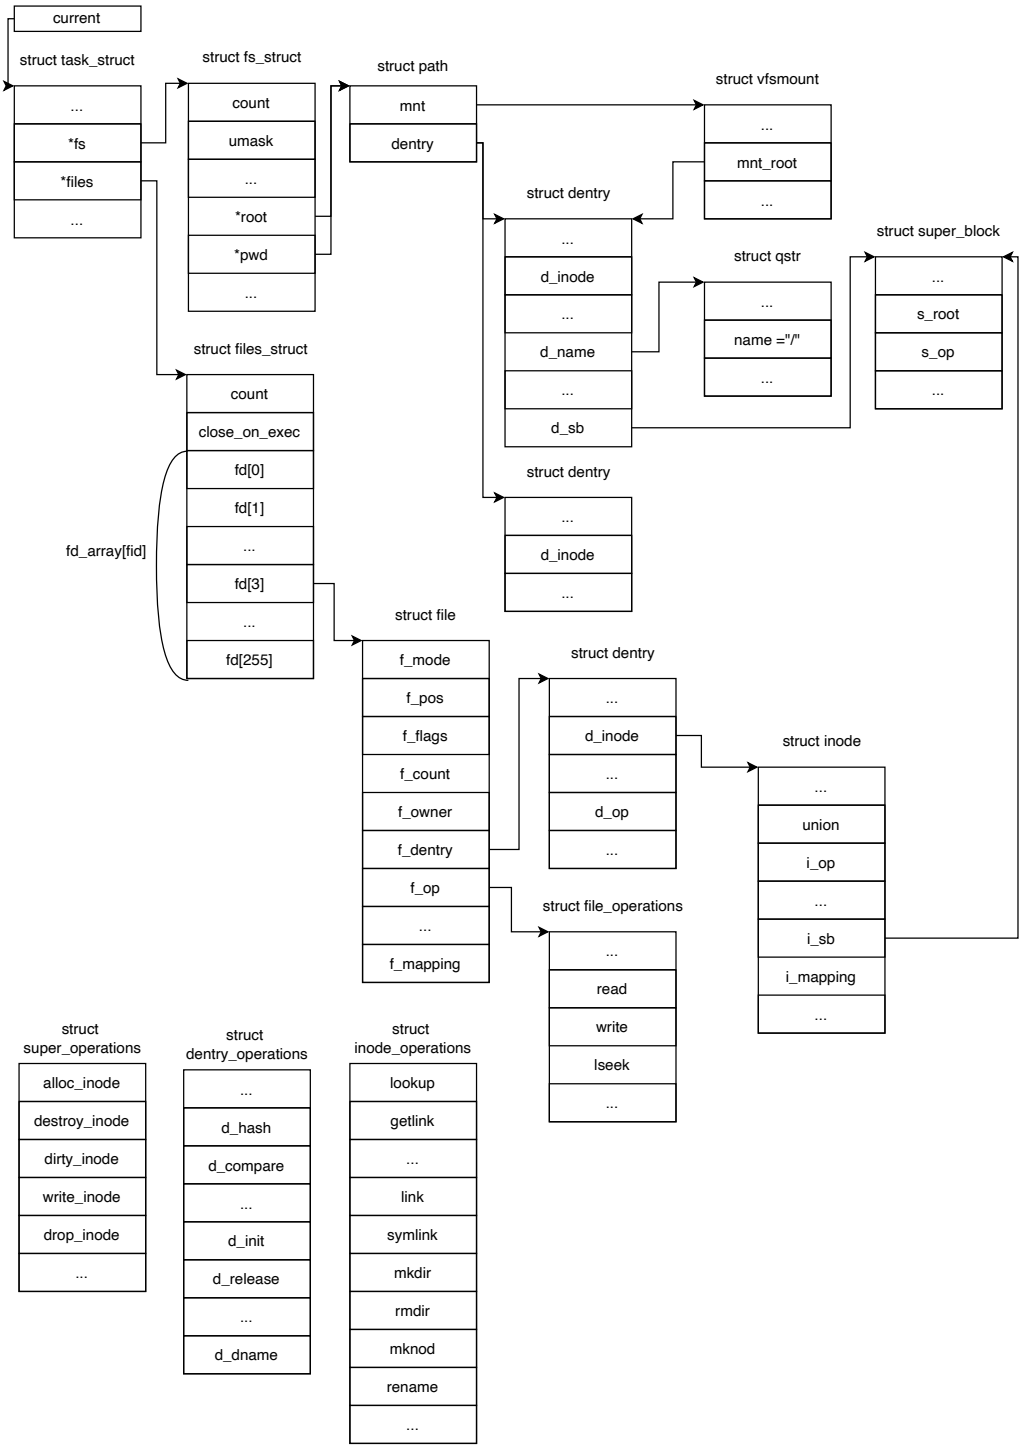

Воспоминания о зарождении процесса

Каждый процесс до того, как он был запущен, был файлом и принадлежал некоторой *вайбовой* системе, поэтому в **struct task_struct** имеется указатель на фс, которой принадлежит файл программы, и указатель на таблицу открытых файлов процесса.

Очевидно, что **struct files_struct** содержит массив дескрипторов открытых файлов (0,1,2,3,4,...).

При этом

- 0 – stdin
- 1 – stdout
- 02– stderr
- 03 – скорая помощь

Эти файлы открываются для процесса автоматически (файловые дескрипторы для этих файлов создаются автоматически).

Когда мы открываем файл, он может получить дескриптор, после этих трех (например, 3,4,5 и тд)

Всего в этой таблице может быть 256 дескрипторов.

struct vfs_mount заполняется, когда файловая система монтируется. Имя – указатель на **struct qstr**.

В **struct super_block** есть указатель на **struct super_operations** (s_op) и на root (s_root), так как корневой каталог (точка монтирования) должен быть создан, чтобы иметь возможность смонтировать файловую систему.

Связи структур из лабы на буферы

1 open, 2 fdopen, буферизация, читали 20 и 6 байт, выводили на экран

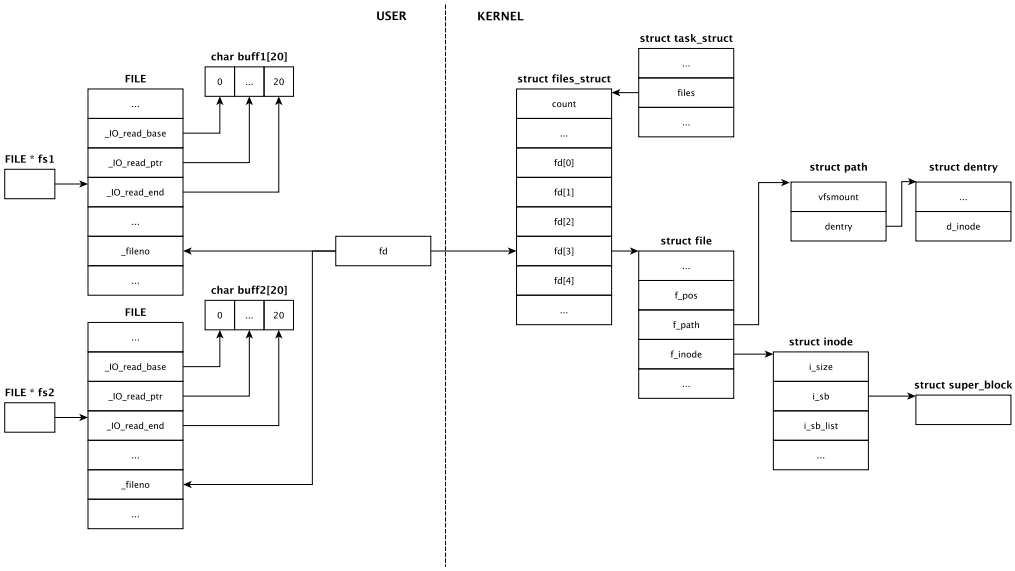

2 open, 2 дескриптора, без буферизации, посимвольно читали и выводили

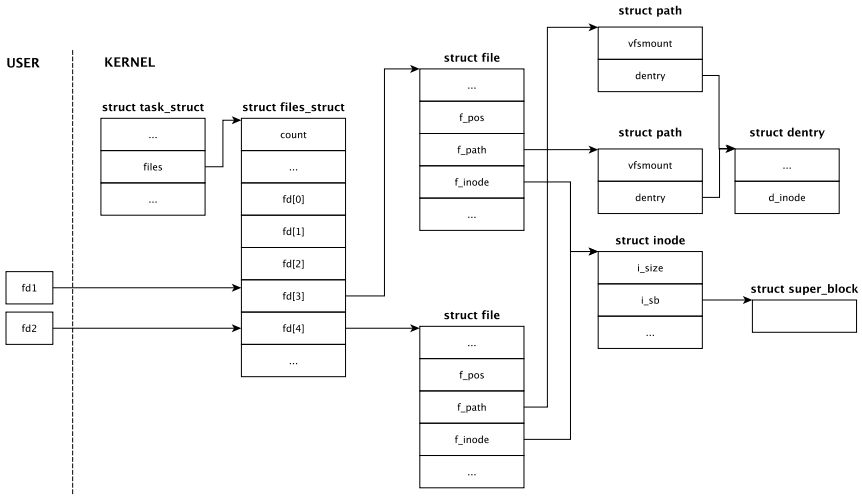

2 opeп, без буферизации и с ней, шли от a до з писали по очереди, 2 разных дескриптора, свои фпоз, записался либо по последнему фклоуз (при буф), либо по райт (посимвольно затирается без буф)

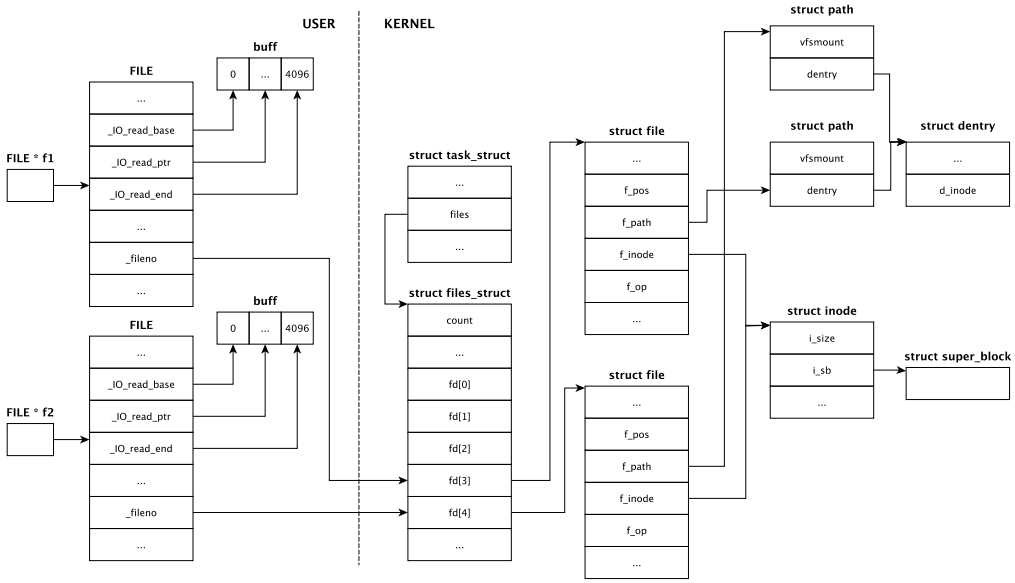

1.4. Библиотечная функция fopen()

fopen() — это функция стандартной библиотеки stdio.h — библиотека буферизованного в/в.

```
1 FILE *fopen(const char *fname, const char *mode);
```

Функция fopen() открывается файл, имя которого указано аргументом fname и возвращает связанный с ним указатель. Тип операций, разрешенных над файлом, определяется аргументом mode.

FILE определена define над IO_FILE — описывает буферизированный ввод вывод, она описана в stdio.h. Ее связывает с дескриптором открытого файла: fileno

Если для fopen() указан O_CREAT, то если 2 раза вызвать так — данные затираются.

Возможно, стоит добавить, что функции библиотеки stdio.h могут работать с форматированныит данными.

1.5. Системный вызов open()

Системный вызов open() открывает файл, определённый *pathname*.

Возвращаемое значение

open() возвращает файловый дескриптор — небольшое неотрицательное целое число, которое является ссылкой на запись в системной таблице открытых файлов и индексом записи в таблице дескрипторов открытых файлов процесса. Этот дескриптор используется далее в системных вызовах read(), write(), lseek(), fcntl() и т.д. для ссылки на открытый файл. В случае успешного вызова будет возвращён наименьший файловый дескриптор, не связанный с открытым процессом файлом.

В случае ошибки возвращается -1 и устанавливается значение errno.

Параметры

pathname — имя файла в файловой системе. Имя файла задается в user mode. *flags* — режим открытия файла — один или несколько флагов открытия, объединенных оператором побитового ИЛИ. *mode* — режим открытия файла.

```
1 #include <sys/types.h>
2 #include <sys/stat.h>
3 #include <fcntl.h>
4
5 int open (const char *pathname, int flags);
```

```
6 int open (const char *pathname, int flags, mode_t mode);
```

2 варианта open():

1. Если ф-ция open предназначени для работы с существующим файлом, то это ф-ция вызывается с 2 параметрами.

2. Если пользователь желает создать файл и использует флаг O_CREATE или O_TMPFILE, то он должен указать 3-й пар-р — mode; Если эти флаги не указаны, то 3-й параметр игнорируется.

Так, можно открыть существующий файл, а можно открыть новый (создать) файл. Создать файл — создать inode.

1.6. Основные флаги. Флаг CREATE

O_CREAT

Если файл не существует, то он будет создан. Владелец (идентификатор пользователя) файла устанавливается в значение эффективного идентификатора пользователя процесса. Группа (идентификатор группы) устанавливается либо в значение эффективного идентификатора группы процесса, либо в значение идентификатора группы родительского каталога (зависит от типа файловой системы, параметров подсоединения (mount) и режима родительского каталога, см. например, параметры подсоединения bsdgroups и sysvgroups файловой системы ext2, как описано в руководстве mount(8)).);

Реальный айди для процесса — который его запустил.

Эффективный айди для процесса — который установлен (может быть изменен, чтобы разрешить доступ не привилегированному пользователю).

O_EXCL

(Если он используется совместно с O_CREAT, то при наличии уже созданного файла вызов open завершится с ошибкой. В этом состоянии, при существующей символьной ссылке не обращается внимание, на что она указывает.);

(Оно не работает в файловых системах NFS, а в программах, использующих этот флаг для создания файла блокировки (если хотим обеспечить создание процесса в единственном экземпляре), возникнет "race condition". Решение для атомарной блокировки файла: создать файл с уникальным именем в той же самой файловой системе.

O_APPEND

(Файл открывается в режиме добавления. Перед каждой операцией write файловый указатель будет устанавливаться в конце файла, как если бы использовался lseek); O_APPEND (этот флаг не работает в NFS, что приведет к гонкам, поэтому будет происходить затирание данных);

O_RDONLY - открыть файл только на чтение

O_WRONLY - открыть файл только на запись

O_RDWR- открыть файл для чтения и записи

O_PATH - получить лишь файловый дескриптор (сам файл не будет открыт). *Будет возвращен дескриптор struct file(он уже существует, мы его не создаем), при этом сам файл не открывается. Если флаг не установлен, то будет организован цикл по всем элтам пути и вызвана ф-ция do_open, которая открывает файл, т.е. создает дескриптор (инициализирует поля struct file).*

O_TMPFILE - создать неименованный временный обычный файл. Предполагает создание временного файла. Если он установлен, будет вызвана ф-ция do_tmpfile.

O_TRUNC - если файл уже существует, он является обычным файлом и заданный режим позволяет записывать в этот файл, то его размер будет установлен в 0 (вся информация будет удалена). Режим доступа и владелец не меняются.

O_LARGEFILE - позволяет открывать файлы, размер которых не может быть представлен типом off_t (long). Для установки должен быть указан макрос _LARGEFILE64_SOURCE.

O_CLOEXEC - устанавливает флаг *close-on-exec* для нового файлового дескриптора, указание этого флага позволяет программе избегать дополнительных операций fcntl F_SETFD для установки флага FD_CLOEXEC. Если close-on-exec установлен, то файловый дескриптор будет автоматически закрыт, когда любая функция из exec-семейства будет вызвана.

O_EXEC - открыть только для выполнения (результат не определен при открытии директории).

Режим (права доступа):

Если мы создаем новый файл, то мы должны указать права доступа к файлу.

Для режима предусмотрены константы (для пользователя/группы):

- S_IRWXU / S_IRWXG - права доступа на чтение, запись и исполнение
- S_IRUSR / S_IRGRP - права на чтение
- S_IWUSR / S_IWGRP - права на запись
- S_IXUSR / S_IXGRP - права на исполнение

1.7. Реализация системного вызова open() в системе – действия в ядре

open(), как и любой системный вызов переводит систему в режим ядра.

Сначала ищется свободный дескриптор в struct files_struct (в массиве дескрипторов открытых файлов процесса), потом при опр. усл-ях создается дескриптор открытого файла в системной таблице открытых файлов, затем при опрю усл-ях создается inode.

1.8. SYSCALL_DEFINE3 (open,...)

В режиме ядра есть syscall table.

В системе есть 6 макросов – syestem call macro. У всех 1 параметр – имя сист. вызова.

С open() работает третий:

SYSCALL_DEFINE3(open, const char __user *filename, int flags, mode_t mode);

```
1  SYSCALL_DEFINE3(open, const char __user *filename, int flags, mode_t
       mode)
2  {
3  if (force_o_largefile())
4       flags |= O_LARGEFILE;
5  return do_sys_open(AT_FDCWD, filename, flags, mode)
6  }
```

filename – имя файла, которое передается из пространства пользователя в пр-во ядра. Это нельзя сделать напрямую. Впоследствии будет вызвана ф-ция str_copy_from_user() для передачи имени файла в ядро (это делается последовательно в результате ряда вызовов функций).

В макросе выполняется проверка того, какая у нас система: если 64-разр., то в ней есть большие файлы (largefile), и флаг O_LARGEFILE добавляется к флагам, к-ые были установлены.

Основная задача макроса – вызов ф-ции ядра do_sys_open()

1.9. do_sys_open()

Создание и инициализация struct
open_how — проверка/установка флагов, режима, вызов do_sys_openat2.

```
1 long do_sys_open(int dfd, const char __user *filename, int flags, umode_t
      mode)
2 {
3   struct open_how how = build_open_how(flags, mode);
4   return do_sys_openat2(dfd, filename, &how);
5 }
```

1.10. do_sys_openat2()

Инициализация структуры open_flags, инициализация структуры filename, поиск свободного файлового дескриптора с пометкой его занятым. Открытие файла, инициализация полей структуры struct file. Если файл открыт, то уведомление ФС об открытии и запись дескриптора открытого файла в таблицу открытых файлов процесса.

```
1 static long do_sys_openat2(int dfd, const char __user *filename,
2           struct open_how *how);
```

1.11. do_filp_open()

Основную работу по открытию файла и связанные с этим действия выполняет ф-ция do_filp_open(). Функция осуществляет обход пути к файлу в 3-ёх возможных режимах:

1. с флагом LOOKUP_RCU — быстрый обход, допускается отсутствие некоторых проверок.
2. обычный обход, если быстрый обход вернул ошибку.
3. с флагом LOOKUP_REVAL — флаг (для работы с NFS) указывает, что необходимо выполнить повторную проверку (чтобы обеспечить принудительную повторную проверку записей, найденных в кеше). В NFS требуются дополнительные проверки, так как в ней не работает
   O_APPEND, следовательно при разделении файлов возникают гонки, приводящие к потере данных.

struct filename и struct open_flags — эти структуры инициализированны в результате работы функций, которые были вызваны ранее

```
1     struct file *do_filp_open(int dfd, struct filename *pathname,
2     const struct open_flags *op);
```

1.12. build_open_flags()

Задачи ф-ции build_open_flags() – инициализация полей struct open_flags на основе флагов, указанных пользователем. В этой функции анализируются все флаги.

```
1  inline int build_open_flags(const struct open_how *how, struct
       open_flags *op);
```

1.13. get_unused_fd_flags()

Можно предположить, что ф-ция get_unused_fd_flags должна найти неиспользуемый файловый дескриптор в таблице дескрипторов открытых файлов для того, чтобы выделить его, и open() мог его вернуть. Вызывает alloc_fd().

```
1  int get_unused_fd_flags(unsigned flags);
```

1.14. alloc_fd()

При этом ф-ция __alloc_fd() использует spin-lock'и, т.к. эти действия могут выполнять несколько процессов/потоков. Ищет наименьший свободный файловый дескриптор с таблице открытых файлов процесса. Если не найден — расширяет таблицу. Помечает найденный файловый дескриптор занятым, устанавливает close-on-exec, возвращает найденный файловый дескриптор.

```
1  static int alloc_fd(unsigned start, unsigned end, unsigned flags);
```

1.15. getname()

Ф-ция getname() вызывает getname_flags(), которая копирует имя файла из пр-ва пользователя в пр-во ядра. При этом используется ф-ция str_copy_from_user().

Для любого процесса файловые дескрипторы 0, 1, 2 (stdin, stdout, stderr) занимаются автоматически, но для этих дескрипторов необходимо проделать все действия так же, как при вызове open() в приложении.

```
1  struct filename *getname_flags(const char __user *filename, int flags,
       int *empty);
```

1.16. set_nameidata()

Ф-ция set_nameidata инициализирует поля struct nameidata.

```
1  static inline void set_nameidata(struct nameidata *p, int dfd, struct
       filename *name, const struct path *root);
```

1.17. restore_nameidata()

Ф-ция restore_nameidata восстанавливает структуру struct nameidata.

```
1  static void restore_nameidata(void);
```

1.18. path_openat()

Функция path_openat возвращает инициализированный дескриптор открытого файла (struct file)

```
1      static struct file *path_openat(struct nameidata *nd,
2        const struct open_flags *op, unsigned flags);
```

1.19. open_last_lookups()

Функция open_last_lookups — разрешение пути при открытии файла (создание предшествующих директорий).

```
1      static const char *open_last_lookups(struct nameidata *nd,
2         struct file *file, const struct open_flags *op);
```

1.20. lookup_open()

Функция lookup_open — создание директории, являющейся частью пути к открываемому файлу, если её нет в dentry cache. Создаются inode.

```
1      static struct dentry *lookup_open(struct nameidata *nd, struct file *
           file, const struct open_flags *op, bool got_write);
```

1.21. do_open()

Функция do_open — проверяет флаги и открывает файл.

```
1  static int do_open(struct nameidata *nd,
2          struct file *file, const struct open_flags *op);
```

1.22. may_open()

Функция may_open — проверяет, возможно ли открыть файл (права доступа, ...).

```
1  static int may_open(struct mnt_idmap *idmap, const struct path *path,
2          int acc_mode, int flag);
```

Функции ядра специфицированы, но не стандартизованы (в отличие от сист. вызовов, которые стандартизованы POSIX). Поэтому функции и структуры ядра переписываются.

Для того, чтобы определить, существует ли файл, нужно пройти по цепочке dentry (задействуется struct dentry).

1.23. Пример

```
1  #include <fcntl.h>  // O_WRONLY
2  #include <unistd.h> // write, close
3  #include <string.h> // strlen
4
5  int main()
6  {
7    int fd1 = open("text.txt", O_WRONLY);
8    int fd2 = open("text.txt", O_WRONLY);
9
10   char *data1 = "aaaaaaaaaaaa";
11   char *data2 = "bbbb";
12
13   write(fd1, data1, strlen(data1));
14   write(fd2, data2, strlen(data2));
15
16   close(fd1);
```

```
17    close(fd2);
18
19    return 0;
20  }
```

Результат: bbbbaaaaaaaa.

В данной программе с помощью системного вызова open() создаются два файловых дескриптора struct file одного и того же файла, то есть создаются две записи в системной таблице открытых файлов. Каждый дескриптор будет иметь своё смещение f_pos. Поэтому каждая строка будет записана в начало файла.

Результат: Данные затерлись (произошла потеря данных).

2 open, 2 дескриптора, без буферизации, посимвольно читали и выводили

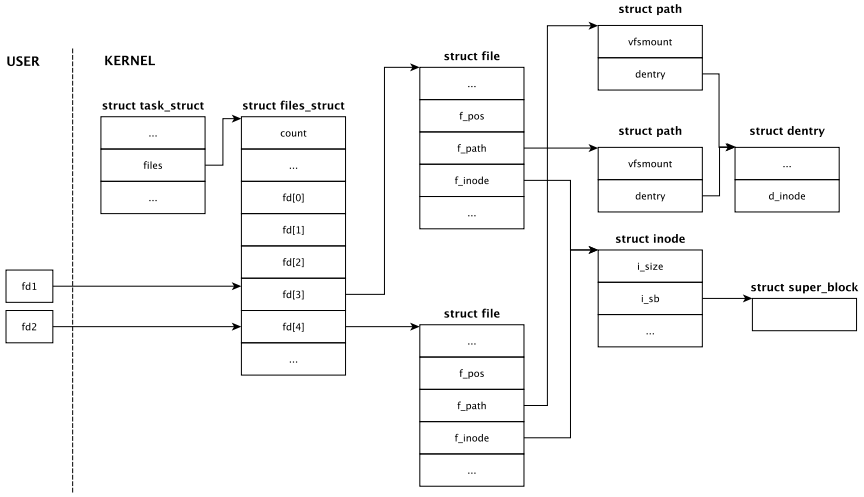

Зогандки

Где видели create_inode из inode_operations? — в опене, lookup_open()

Где видели семафоры read/write? — в open_last_lookups():

```
1   if (open_flag & O_CREAT)
2     inode_lock(dir->d_inode);
3   else
4     inode_lock_shared(dir->d_inode);
5   dentry = lookup_open(nd, file, op, got_write);
6   if (!IS_ERR(dentry) && (file->f_mode & FMODE_CREATED))
```

```
7       fsnotify_create(dir->d_inode, dentry);
8     if (open_flag & O_CREAT)
9       inode_unlock(dir->d_inode);
10    else
11      inode_unlock_shared(dir->d_inode);
```

Реализация

```
1  static inline void inode_lock(struct inode *inode)
2  {
3    down_write(&inode->i_rwsem);
4  }
5  static inline void inode_unlock(struct inode *inode)
6  {
7    up_write(&inode->i_rwsem);
8  }
9  static inline void inode_lock_shared(struct inode *inode)
10 {
11   down_read(&inode->i_rwsem);
12 }
13 static inline void inode_unlock_shared(struct inode *inode)
14 {
15   up_read(&inode->i_rwsem);
16 }
```

LOOKUP_REVAL — флаг (для работы с NFS) указывает, что необходимо выполнить повторную проверку (чтобы обеспечить принудительную повторную проверку записей, найденных в кеше). В NFS требуются дополнительные проверки, так как в ней не работает O_APPEND, следовательно при разделении файлов возникают гонки, приводящие к потере данных.

Интересно, что сискал опена разбит на много функций!

Как проверяется существует ли файл? — по имени

Тонкий момент в alloc_fd? — если свободный ФД в таблице не найден, то создается новая таблица:

```
1  /*
2   * Expand files.
3   * This function will expand the file structures, if the requested size
        exceeds
4   * the current capacity and there is room for expansion.
```

```
5   * Return <0 error code on error; 0 when nothing done; 1 when files were
6   * expanded and execution may have blocked.
7   * The files->file_lock should be held on entry, and will be held on exit.
8   */
9  static int expand_files(struct files_struct *files, unsigned int nr)
```

Давно когда-то файлы были маленькие, их было много, не было БД: 256 было достаточно. Сейчас есть большие файлы, соответственно количество меньше.

Что такое имя? — Каждый каталог и файл файловой системы имеет уникальное полное имя full pathname - имя, задающее полный путь от корня файловой системы через цепочку каталогов к соответствующему каталогу или файлу. Абсолютное имя содержит путь относительно корня "/". Короткое или относительное имя файла (relative pathname) - имя (возможно, составное), задающее путь к файлу от текущего рабочего каталога. Имя файла задается в user mode.